

Análise e Processamento de Imagens para Detecção e Alerta de Transporte Emergencial

Felipe do Nascimento Fonseca¹, Gabriel Barros Albertini¹, Rafael de Menezes Ros¹, Vinicius Alves Marques¹

¹ Faculdade de Computação e Informática – Universidade Presbiteriana Mackenzie
(UPM)
São Paulo – SP – Brasil

{felipenascimento.fonseca, gabriel.albertini, rafael.ros,
vinicius.marques}@mackenzista.com.br

Abstract. *This work proposes an Artificial Intelligence system based on Computer Vision capable of recognizing emergency vehicles, such as ambulances, through urban traffic monitoring sources (e.g., CET camera systems). The objective is to generate alerts for integrated systems that can, for instance, prioritize traffic signal control to facilitate and accelerate the movement of these vehicles toward their emergency destinations. The proposal aims to improve the quality of emergency healthcare services in urban environments within the context of Smart Cities, making them more effective and efficient by reducing response times in urgent situations, thereby increasing the chances of saving lives.*

Resumo. *Uma IA baseada em Visão Computacional capaz de reconhecer veículos de emergência, como ambulâncias, através de sites de monitoramento como da CET com o objetivo de enviar um alerta para um sistema que pode, por exemplo, priorizar a abertura de faróis para acelerar o deslocamento do veículo ao seu destino emergencial. A proposta tem a finalidade de aumentar a qualidade do serviço de emergência de saúde nas cidades (no contexto de Smart Cities), tornando-o mais eficaz e eficiente ao reduzir o tempo de deslocamento em atendimentos de urgência, assim aumentando a chance de salvar vidas.*

1. Introdução

1.1. Contextualização

A expansão acelerada de grandes centros urbanos e o aumento considerável no número de veículos têm gerado impactos na mobilidade urbana. Em situações de emergências médicas, o tempo de deslocamento de veículos de emergência como ambulância é um fator crítico para o atendimento de pacientes. A falta de uma tecnologia que possa priorizar a passagem de veículos de emergência em, por exemplo, situações de congestionamentos, podem atrasar os atendimentos e a eficácia do sistema de saúde (KHAN et al., 2018).

Nesse contexto, o avanço da Inteligência Artificial (IA) possibilita o desenvolvimento de sistemas capazes de analisar imagens e vídeos em tempo real para identificar padrões e objetos específicos (RUSSELL; NORVIG, 2021). As câmeras de monitoramento do tráfego urbano podem servir como fonte de dados para os sistemas inteligentes, permitindo a aplicação de técnicas de visão computacional para interpretação de cenas (SZELISKI, 2010).

A utilização desse tipo de dentro do conceito de Smart Cities permite integrar dados urbanos a sistemas automatizados de tomada de decisão, possibilitando melhorias na gestão do trânsito e na eficiência dos serviços públicos (ZHANG et al., 2017).

1.2. Justificativa

O tempo de resposta em atendimentos médicos emergenciais é um fator determinante para a sobrevivência e recuperação de pacientes. Em muitos casos, minutos podem representar a diferença entre a vida e a morte. No entanto, em grandes centros urbanos, o tráfego intenso frequentemente impede o deslocamento rápido de ambulâncias e outros veículos de emergência (KHAN et al., 2018).

Diante desse cenário, o uso de técnicas de processamento de imagens e visão computacional pode contribuir para a identificação automática desses veículos no trânsito (LECUN; BENGIO; HINTON, 2015). E, a partir dela, agentes inteligentes podem emitir alertas ou acionar mecanismos de priorização no fluxo, como a abertura coordenada de semáforos (SINGH; GUPTA, 2020).

1.3. Objetivo

O objetivo deste projeto é desenvolver um sistema baseado em Inteligência Artificial capaz de identificar ambulâncias a partir de imagens de câmeras de monitoramento urbano. A partir dela, gerar alertas para priorização de passagem de ambulâncias no tráfego urbano por meio da abertura de semáforos. Dessa forma, busca-se reduzir o tempo de deslocamento em situações de emergência e, consequentemente, aumentar a eficiência e eficácia dos atendimentos médicos.

1.4. Opção do projeto

No contexto de Machine Learning e Visão Computacional, propõe-se treinar um detector leve de objetos, como *YOLOv8n* ou *YOLO11n*, utilizando transfer learning, iniciando a partir de um modelo pré-treinado e ajustando-o especificamente para a classe “ambulância”. Após o treinamento, o modelo deve ser avaliado por meio de métricas como *precision*, *recall* e *mAP*, além de testes com pequenos vídeos para

verificar seu desempenho. Em seguida, implementar uma regra: ao detectar uma ambulância por N frames consecutivos, o sistema gera um alerta. Como resultado, pretende-se entregar um protótipo em notebook ou *Streamlit*, capaz de processar vídeos e exibir as caixas de detecção, o nível de confiança e o alerta gerado.

2. Fundamentação Teórica

2.1. Conceitos fundamentais

A Inteligência Artificial (IA) é definida como a área da ciência da computação dedicada ao desenvolvimento de sistemas capazes de simular capacidades humanas, como aprendizado, percepção e tomada de decisão (RUSSELL; NORVIG, 2021). Dentro desse contexto, o Machine Learning (ML) destaca-se por permitir que algoritmos aprendam padrões a partir de dados, sem a necessidade de regras explicitamente programadas.

Um dos principais subcampos utilizados neste trabalho é a Visão Computacional, responsável pela extração de informações relevantes a partir de imagens e vídeos digitais. Segundo SZELISKI (2010), essa área combina técnicas de processamento de imagens com modelos matemáticos e estatísticos para interpretar o conteúdo visual.

Nos últimos anos, o avanço do Deep Learning revolucionou a área, especialmente com o uso de Redes Neurais Convolucionais (CNNs). Essas redes são projetadas para processar dados estruturados em grade, como imagens, sendo altamente eficazes na extração automática de características (LECUN; BENGIO; HINTON, 2015).

Para tarefas de detecção de objetos, que envolvem identificar e localizar múltiplos objetos em uma imagem, destacam-se modelos como o YOLO (*You Only Look Once*), proposto por REDMON et al. (2016). Esse tipo de abordagem realiza a detecção em uma única etapa, proporcionando alto desempenho em tempo real — característica essencial para aplicações em monitoramento urbano.

Além disso, técnicas como transfer learning são amplamente utilizadas para reduzir o custo de treinamento, reutilizando modelos pré-treinados em grandes bases de dados e ajustando-os para tarefas específicas (PAN; YANG, 2010).

A avaliação desses modelos é realizada por meio de métricas como precision, recall e mean Average Precision (mAP), que permitem mensurar a qualidade das detecções realizadas (EVERINGHAM et al., 2010).

Por fim, o projeto está inserido no contexto de Smart Cities, no qual tecnologias digitais são utilizadas para melhorar a eficiência dos serviços urbanos, incluindo mobilidade e atendimento emergencial, integrando dados em tempo real para tomada de decisão automatizada (ZHANG et al., 2017).

2.2. Trabalhos Relacionados

A aplicação de técnicas de Visão Computacional no monitoramento de tráfego tem sido amplamente explorada na literatura. Trabalhos como o de ZHANG et al. (2017) demonstram o uso de redes neurais profundas para detecção e classificação de veículos em ambientes urbanos, alcançando alta precisão em cenários complexos.

No contexto específico de detecção em tempo real, modelos da família YOLO têm sido amplamente adotados devido ao seu equilíbrio entre velocidade e acurácia (REDMON et al., 2016). Estudos recentes indicam que versões mais leves desses modelos são adequadas para aplicações em tempo real com restrições computacionais, como sistemas embarcados e monitoramento urbano.

Além disso, pesquisas voltadas à priorização de veículos de emergência têm sido desenvolvidas utilizando diferentes abordagens. Algumas soluções utilizam sensores e comunicação via IoT entre veículos e infraestrutura (KHAN et al., 2018), enquanto outras exploram o uso de visão computacional para identificar automaticamente ambulâncias em fluxos de tráfego (SINGH; GUPTA, 2020).

Comparativamente, abordagens baseadas em visão computacional apresentam vantagens por não exigirem modificações nos veículos ou infraestrutura adicional, utilizando apenas câmeras já existentes, como as de monitoramento urbano. Essa característica torna a solução mais escalável e de menor custo.

O presente trabalho diferencia-se ao propor a integração de um modelo leve de detecção com regras de decisão baseadas em múltiplos frames, aplicadas sobre dados reais de monitoramento urbano, visando uma solução prática para redução do tempo de resposta em emergências médicas.

3. Metodologia e Resultados Esperados

3.1. Abordagem, etapas e resultados esperados

A metodologia deste projeto baseia-se no desenvolvimento de um sistema de detecção automática de ambulâncias em vídeos de tráfego urbano provenientes de câmeras fixas, utilizando técnicas de Visão Computacional e aprendizado profundo.

A abordagem adotada segue um fluxo incremental, iniciando pela coleta e análise dos dados, passando pelo treinamento de modelos e finalizando com a construção de um protótipo funcional.

Inicialmente, será realizada a seleção de datasets públicos adequados ao problema, seguida de uma análise exploratória dos dados. Essa etapa permitirá compreender as características das imagens, como variações de iluminação, ângulos de captura, presença de oclusões e diversidade de cenários urbanos.

Em seguida, será conduzido o treinamento de um modelo de detecção de objetos baseado em arquiteturas do tipo YOLO (REDMON et al., 2016), como YOLOv8, utilizando a técnica de transfer learning (PAN; YANG, 2010). O modelo será inicializado com pesos pré-treinados e ajustado especificamente para a classe “ambulância”, tornando o processo mais eficiente e viável dentro do tempo disponível para o projeto.

Após o treinamento, o modelo será avaliado utilizando métricas consolidadas da área, como precision, recall e mean Average Precision (mAP) (EVERINGHAM et al., 2010), além de testes qualitativos em vídeos de tráfego urbano. Com base nesses resultados, será implementada uma lógica de decisão temporal: caso uma ambulância seja detectada em um número consecutivo de frames (N), o sistema deverá gerar um alerta.

Como etapa final, será desenvolvido um protótipo funcional, utilizando ferramentas como notebooks interativos ou aplicações web com Streamlit. Esse protótipo deverá ser capaz de processar vídeos, exibir as detecções com caixas delimitadoras, apresentar o nível de confiança das previsões e indicar visualmente o acionamento do alerta.

Como resultados esperados, propõem-se obter um modelo capaz de identificar ambulâncias com boa precisão em cenários urbanos, além de um protótipo demonstrável que evidencie a viabilidade da solução no contexto de cidades inteligentes, contribuindo para a redução do tempo de resposta em emergências.

3.2. Dataset, descrição do conteúdo de origem, análise exploratória e preparação dos dados

Para o desenvolvimento do modelo, será utilizado como dataset principal o Emergency Vehicle Detection (Roboflow), que contém imagens rotuladas de veículos de emergência, incluindo ambulâncias, viaturas policiais e caminhões de bombeiros. Esse conjunto de dados é adequado para o problema por já possuir anotações no formato necessário para tarefas de detecção de objetos.

Com o objetivo de aumentar a robustez do modelo em cenários urbanos reais, serão utilizados datasets complementares, como o BDD100K e o UA-DETRAC, que apresentam grande diversidade de condições de tráfego, iluminação, clima e densidade veicular.

A análise exploratória dos dados (EDA) envolverá a investigação dos seguintes aspectos:

- Distribuição das classes (ambulância, outros veículos);
- Quantidade de exemplos por classe;
- Variações de iluminação (dia/noite);
- Diferentes ângulos de câmera (câmeras fixas urbanas);
- Presença de oclusões (veículos parcialmente visíveis);
- Identificação de exemplos difíceis ou ambíguos.

Essa etapa permitirá verificar possíveis problemas de desbalanceamento de classes, especialmente a menor quantidade de imagens de ambulâncias em comparação com outros veículos, o que pode impactar o desempenho do modelo.

4. Resultados parciais

4.1. Aspectos éticos do uso da IA e responsabilidade no desenvolvimento da solução

O desenvolvimento de sistemas baseados em Inteligência Artificial para monitoramento urbano, como o proposto neste projeto, envolve uma série de questões éticas que devem ser cuidadosamente consideradas, especialmente por lidar com dados visuais coletados em espaços públicos e por influenciar decisões automatizadas no trânsito.

Um dos principais aspectos éticos refere-se à privacidade e à proteção de dados. O uso das imagens provenientes das câmeras de monitoramento urbano para o

treinamento e operação de modelos de IA deve respeitar legislações vigentes, como a Lei Geral de Proteção de Dados (LGPD), que estabelece diretrizes para o tratamento de dados pessoais e a proteção da privacidade dos indivíduos (BRASIL, 2018). Dessa forma, é fundamental garantir que os dados utilizados sejam públicos, anonimizados ou devidamente autorizados, evitando a identificação de indivíduos e o uso indevido de informações sensíveis.

A confiabilidade do sistema e a robustez do modelo também são pontos críticos. Erros de detecção podem gerar impactos no trânsito, como abertura indevida de semáforos (falsos positivos) ou falha na priorização de ambulâncias (falsos negativos). Por isso, o modelo deve ser bem avaliado e utilizado, preferencialmente, como suporte à decisão, e não como sistema totalmente autônomo. A legislação brasileira também prevê o direito à revisão de decisões automatizadas, reforçando a importância da supervisão humana nesses sistemas (BRASIL, 2018).

Além disso, é importante garantir transparência nos critérios de funcionamento e atenção a possíveis vieses nos dados, que podem afetar o desempenho nos diferentes cenários urbanos.

Por fim, o projeto apresenta um impacto social positivo ao contribuir para a redução do tempo de resposta em emergências. No entanto, esse benefício depende de um desenvolvimento responsável, seguro e alinhado aos princípios éticos em todas as etapas da solução.

4.2. Detalhamento dos resultados parciais

Inicialmente, foi realizado o treinamento de um modelo base utilizando a arquitetura YOLOv8n, sem a aplicação de técnicas avançadas de pré-processamento ou inclusão de datasets adicionais. O treinamento foi conduzido conforme a configuração a seguir:

```
model = YOLO("yolov8n.pt")

model.train(
    data="/content/-Emergency-Vehicle-Detection--1/data.yaml",
    epochs=30,
    imgsz=640
)
```

Tabela 1. Métricas de desempenho do modelo

Métrica	Valor	Descrição
Precision	0,967	Proporção de detecções corretas em relação ao total de detecções feitas
Recall	0,973	Capacidade do modelo de identificar todos os objetos relevantes
mAP@50	0,983	Média da precisão considerando $\text{IoU} \geq 0,50$

Métrica	Valor	Descrição
mAP@50-95	0,747	Média da precisão em múltiplos níveis de IoU (mais rigoroso)
Fitness	0,747	Métrica agregada baseada no desempenho geral do modelo
Tempo de inferência	~2 ms	Tempo médio para processar uma imagem
Tempo total	~4 ms	Inferência + pós-processamento

Tabela 2. Desempenho por classe

Classe	mAP@50-95	Nº de amostras
Ambulance	0,735	148
Fire Engine	0,739	121
Police Vehicle	0,766	177

Os resultados obtidos indicam um desempenho geral satisfatório para o estágio inicial do projeto. A métrica de *fitness*, associada ao mAP@50-95, atingiu o valor de 0,747, refletindo a capacidade do modelo em realizar detecções consistentes sob critérios mais rigorosos de avaliação.

O modelo apresentou mAP@50 igual a 0,983, indicando alta eficiência na detecção e localização dos objetos sob um critério menos restritivo. Além disso, foram obtidos valores elevados de *precision* (0,967) e *recall* (0,973), demonstrando que o modelo possui baixo índice de falsos positivos e elevada capacidade de identificar corretamente os objetos presentes nas imagens.

A análise por classe revelou um desempenho equilibrado entre as categorias “Ambulance” (0,735), “Fire Engine” (0,739) e “Police Vehicle” (0,766), indicando ausência de viés significativo entre as classes. A distribuição das amostras (148, 121 e 177, respectivamente) contribui para essa consistência, embora o volume total de dados ainda seja limitado, o que pode impactar a generalização do modelo.

Em relação ao desempenho computacional, o modelo apresentou tempo médio de inferência de aproximadamente 2 ms por imagem, com pós-processamento na mesma ordem de grandeza, totalizando cerca de 4 ms. Esse resultado evidencia a viabilidade do uso do modelo em aplicações em tempo real, como o monitoramento contínuo de câmeras de trânsito.

De forma geral, os resultados indicam que o modelo atende aos objetivos iniciais do projeto, sendo capaz de detectar veículos de emergência com boa precisão. Como trabalhos futuros, destacam-se a ampliação e diversificação do dataset, incluindo diferentes condições ambientais, bem como o ajuste fino do modelo para melhorar o desempenho em métricas mais rigorosas.

4.3. Link do GitHub

[hyauss/DeteccaoEAlertaDeTransporteEmergencialViaImagens](#)

Referências

RUSSELL, S.; NORVIG, P. Artificial Intelligence: A Modern Approach. 4. ed. Pearson, 2021.

SZELISKI, R. Computer Vision: Algorithms and Applications. Springer, 2010.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. Nature, v. 521, 2015.

REDMON, J. et al. You Only Look Once: Unified, Real-Time Object Detection. CVPR, 2016.

PAN, S. J.; YANG, Q. A Survey on Transfer Learning. IEEE Transactions on Knowledge and Data Engineering, 2010.

EVERINGHAM, M. et al. The Pascal Visual Object Classes (VOC) Challenge. IJCV, 2010.

ZHANG, S. et al. Deep learning based vehicle detection. IEEE Transactions on Intelligent Transportation Systems, 2017.

KHAN, M. A. et al. Smart traffic control system for emergency vehicles. IEEE, 2018.

SINGH, A.; GUPTA, B. Intelligent ambulance detection system. Procedia Computer Science, 2020.

BRASIL. Lei nº 13.709/2018. Lei Geral de Proteção de Dados Pessoais (LGPD).