



**UNIVERSIDADE PRESBITERIANA MACKENZIE**  
**Faculdade de Computação e Informática**

**Prof. Dr. Ivan Carlos Alcântara de Oliveira**  
**Inteligência Artificial**



**ANÁLISE E PROCESSAMENTO DE IMAGENS PARA DETECÇÃO E  
ALERTA DE TRANSPORTE EMERGENCIAL**

**INTEGRANTES**

Gabriel Barros Albertini - 10419482

Rafael de Menezes Ros - 10417954

Vinicius Alves Marques - 10417880

Felipe do Nascimento Fonseca - 10409389

**SUMÁRIO**

1. Resumo
2. Introdução
3. Fundamentação Teórica
  - 3.1. Conceitos fundamentais
  - 3.2. Trabalhos relacionados
4. Metodologia e Resultados Esperados
  - 4.1. Abordagem, etapas e resultados esperados
  - 4.2. Dataset, descrição do conteúdo de origem, análise exploratória e preparação dos dados
5. Resultados
  - 5.1. Aspectos éticos do uso da IA e responsabilidade no desenvolvimento da solução
  - 5.2. Detalhamento dos resultados completos
  - 5.3. Endereço GitHub e Endereço do vídeo no YouTube
6. Conclusão
7. Referências

## 1. Resumo

Uma IA baseada em Visão Computacional capaz de reconhecer veículos de emergência, como ambulâncias, através de sites de monitoramento como da CET com o objetivo de enviar um alerta para um sistema que pode, por exemplo, priorizar a abertura de faróis para acelerar o deslocamento do veículo ao seu destino emergencial. A proposta tem a finalidade de aumentar a qualidade do serviço de emergência de saúde nas cidades (no contexto de *Smart Cities*), tornando-o mais eficaz e eficiente ao reduzir o tempo de deslocamento em atendimentos de urgência, assim aumentando a chance de salvar vidas.

## 2. Introdução

A expansão acelerada de grandes centros urbanos e o aumento considerável no número de veículos têm gerado impactos na mobilidade urbana. Em situações de emergências médicas, o tempo de deslocamento de veículos de emergência como ambulância é um fator crítico para o atendimento de pacientes. A falta de uma tecnologia que possa priorizar a passagem de veículos de emergência em, por exemplo, situações de congestionamentos, podem atrasar os atendimentos e a eficácia do sistema de saúde (KHAN *et al.*, 2018). Nesse contexto, o avanço da Inteligência Artificial (IA) possibilita o desenvolvimento de sistemas capazes de analisar imagens e vídeos em tempo real para identificar padrões e objetos específicos (RUSSELL; NORVIG, 2021). As câmeras de monitoramento do tráfego urbano podem servir como fonte de dados para os sistemas inteligentes, permitindo a aplicação de técnicas de visão computacional para interpretação de cenas (SZELISKI, 2010). A utilização desse tipo de dentro do conceito de Smart Cities permite integrar dados urbanos a sistemas automatizados de tomada de decisão, possibilitando melhorias na gestão do trânsito e na eficiência dos serviços públicos (ZHANG *et al.*, 2017).

O tempo de resposta em atendimentos médicos emergenciais é um fator determinante para a sobrevivência e recuperação de pacientes. Em muitos casos, minutos podem representar a diferença entre a vida e a morte. No entanto, em grandes centros urbanos, o tráfego intenso frequentemente impede o deslocamento rápido de ambulâncias e outros veículos de emergência (KHAN *et al.*, 2018). Diante desse cenário, o uso de técnicas de processamento de imagens e visão computacional pode contribuir para a identificação automática desses veículos no trânsito (LECUN; BENGIO; HINTON, 2015). E, a partir dela, agentes inteligentes podem emitir alertas ou acionar mecanismos de priorização no fluxo, como a abertura coordenada de semáforos (SINGH; GUPTA, 2020).

O objetivo deste projeto é desenvolver um sistema baseado em Inteligência Artificial capaz de identificar ambulâncias a partir de imagens de câmeras de monitoramento urbano. A partir dela, gerar alertas para priorização de passagem de ambulâncias no tráfego urbano por meio da abertura de semáforos. Dessa forma, busca-se reduzir o tempo de deslocamento em situações de emergência e, conseqüentemente, aumentar a eficiência e eficácia dos atendimentos médicos. Para isso, propõe-se treinar um detector leve de objetos, como

*YOLOv8n* ou *YOLO11n*, utilizando transfer learning, iniciando a partir de um modelo pré-treinado e ajustando-o especificamente para a classe “ambulância”. Após o treinamento, o modelo deve ser avaliado por meio de métricas como *precision*, *recall* e mAP, além de testes com pequenos vídeos para verificar seu desempenho. Em seguida, implementar uma regra: ao detectar uma ambulância por N frames consecutivos, o sistema gera um alerta. Como resultado, pretende-se entregar um protótipo em notebook ou *Streamlit*, capaz de processar vídeos e exibir as caixas de detecção, o nível de confiança e o alerta gerado.

Ao longo do trabalho, serão apresentados os fundamentos teóricos que sustentam a proposta, incluindo conceitos de inteligência artificial, visão computacional e aprendizado profundo, além de trabalhos relacionados que exploram soluções semelhantes. Em seguida, será detalhada a metodologia adotada, contemplando a escolha dos datasets, o processo de treinamento do modelo e os resultados esperados. Por fim, serão discutidos os resultados obtidos, os aspectos éticos envolvidos no uso da IA para monitoramento urbano e as conclusões sobre a viabilidade da solução proposta.

### **3. Fundamentação Teórica**

#### **3.1. Conceitos fundamentais**

A Inteligência Artificial (IA) é definida como a área da ciência da computação dedicada ao desenvolvimento de sistemas capazes de simular capacidades humanas, como aprendizado, percepção e tomada de decisão (RUSSELL; NORVIG, 2021). Dentro desse contexto, o *Machine Learning* (ML) destaca-se por permitir que algoritmos aprendam padrões a partir de dados, sem a necessidade de regras explicitamente programadas.

Um dos principais subcampos utilizados neste trabalho é a Visão Computacional, responsável pela extração de informações relevantes a partir de imagens e vídeos digitais. Segundo SZELISKI (2010), essa área combina técnicas de processamento de imagens com modelos matemáticos e estatísticos para interpretar o conteúdo visual.

Nos últimos anos, o avanço do *Deep Learning* revolucionou a área, especialmente com o uso de Redes Neurais Convolucionais (CNNs). Essas redes são projetadas para processar dados estruturados em grade, como imagens, sendo altamente eficazes na extração automática de características (LECUN; BENGIO; HINTON, 2015).

Para tarefas de detecção de objetos, que envolvem identificar e localizar múltiplos objetos em uma imagem, destacam-se modelos como o YOLO (*You Only Look Once*), proposto por REDMON *et al.* (2016). Esse tipo de abordagem realiza a detecção em uma única etapa, proporcionando alto desempenho em tempo real — característica essencial para aplicações em monitoramento urbano.

Além disso, técnicas como transfer learning são amplamente utilizadas para reduzir o custo de treinamento, reutilizando modelos pré-treinados em grandes bases de dados e ajustando-os para tarefas específicas (PAN; YANG, 2010).

A avaliação desses modelos é realizada por meio de métricas como *precision*, *recall* e *mean Average Precision* (mAP), que permitem mensurar a qualidade das detecções realizadas (EVERINGHAM *et al.*, 2010).

Por fim, o projeto está inserido no contexto de *Smart Cities*, no qual tecnologias digitais são utilizadas para melhorar a eficiência dos serviços urbanos, incluindo mobilidade e atendimento emergencial, integrando dados em tempo real para tomada de decisão automatizada (ZHANG *et al.*, 2017).

### **3.2. Trabalhos relacionados**

A aplicação de técnicas de Visão Computacional no monitoramento de tráfego tem sido amplamente explorada na literatura. Trabalhos como o de ZHANG *et al.* (2017) demonstram o uso de redes neurais profundas para detecção e classificação de veículos em ambientes urbanos, alcançando alta precisão em cenários complexos.

No contexto específico de detecção em tempo real, modelos da família YOLO têm sido amplamente adotados devido ao seu equilíbrio entre velocidade e acurácia (REDMON *et al.*, 2016). Estudos recentes indicam que versões mais leves desses modelos são adequadas para aplicações em tempo real com restrições computacionais, como sistemas embarcados e monitoramento urbano.

Além disso, pesquisas voltadas à priorização de veículos de emergência têm sido desenvolvidas utilizando diferentes abordagens. Algumas soluções utilizam sensores e comunicação via IoT entre veículos e infraestrutura (KHAN *et al.*, 2018), enquanto outras exploram o uso de visão computacional para identificar automaticamente ambulâncias em fluxos de tráfego (SINGH; GUPTA, 2020).

Comparativamente, abordagens baseadas em visão computacional apresentam vantagens por não exigirem modificações nos veículos ou infraestrutura adicional, utilizando apenas câmeras já existentes, como as de monitoramento urbano. Essa característica torna a solução mais escalável e de menor custo.

O presente trabalho diferencia-se ao propor a integração de um modelo leve de detecção com regras de decisão baseadas em múltiplos frames, aplicadas sobre dados reais de monitoramento urbano, visando uma solução prática para redução do tempo de resposta em emergências médicas.

## **4. Metodologia e Resultados Esperados**

#### 4.1. Abordagem, etapas e resultados esperados

A metodologia deste projeto baseia-se no desenvolvimento de um sistema de detecção automática de ambulâncias em vídeos de tráfego urbano provenientes de câmeras fixas, utilizando técnicas de Visão Computacional e aprendizado profundo.

A abordagem adotada segue um fluxo incremental, iniciando pela coleta e análise dos dados, passando pelo treinamento de modelos e finalizando com a construção de um protótipo funcional.

Inicialmente, será realizada a seleção de *datasets* públicos adequados ao problema, seguida de uma análise exploratória dos dados. Essa etapa permitirá compreender as características das imagens, como variações de iluminação, ângulos de captura, presença de oclusões e diversidade de cenários urbanos.

Em seguida, será conduzido o treinamento de um modelo de detecção de objetos baseado em arquiteturas do tipo YOLO (REDMON *et al.*, 2016), como YOLOv8, utilizando a técnica de *transfer learning* (PAN; YANG, 2010). O modelo será inicializado com pesos pré-treinados e ajustado especificamente para a classe “ambulância”, tornando o processo mais eficiente e viável dentro do tempo disponível para o projeto.

Após o treinamento, o modelo será avaliado utilizando métricas consolidadas da área, como *precision*, *recall* e *mean Average Precision* (mAP) (EVERINGHAM *et al.*, 2010), além de testes qualitativos em vídeos de tráfego urbano. Com base nesses resultados, será implementada uma lógica de decisão temporal: caso uma ambulância seja detectada em um número consecutivo de frames (N), o sistema deverá gerar um alerta.

Como etapa final, será desenvolvido um protótipo funcional, utilizando ferramentas como *notebooks* interativos ou aplicações web com *Streamlit*. Esse protótipo deverá ser capaz de processar vídeos, exibir as detecções com caixas delimitadoras, apresentar o nível de confiança das previsões e indicar visualmente o acionamento do alerta.

Como resultados esperados, propõem-se obter um modelo capaz de identificar ambulâncias com boa precisão em cenários urbanos, além de um protótipo demonstrável que evidencie a viabilidade da solução no contexto de cidades inteligentes, contribuindo para a redução do tempo de resposta em emergências.

#### 4.2. Dataset, descrição do conteúdo de origem, análise exploratória e preparação dos dados

Para o desenvolvimento do modelo, será utilizado como *dataset* principal o *Emergency Vehicle Detection (Roboflow)*, que contém imagens rotuladas de veículos de emergência, incluindo ambulâncias, viaturas policiais e caminhões de bombeiros. Esse conjunto de dados é adequado ao problema por já possuir anotações no formato necessário

para tarefas de detecção de objetos. Com o objetivo de aumentar a robustez do modelo em cenários urbanos reais, serão utilizados *datasets* complementares, como o BDD100K e o UA-DETRAC, que apresentam grande diversidade de condições de tráfego, iluminação, clima e densidade veicular.

A análise exploratória dos dados (EDA) envolverá aspectos como a distribuição das classes, a quantidade de exemplos por categoria, variações de iluminação (dia/noite), diferentes ângulos de câmera, presença de oclusões e identificação de exemplos difíceis ou ambíguos. O dataset contém três classes principais: ambulância, viatura policial e caminhão de bombeiros. Observa-se que há maior quantidade de imagens de viaturas policiais e menor número de ambulâncias, o que pode impactar diretamente o desempenho do modelo, levando-o a reconhecer melhor classes mais frequentes e apresentar menor precisão na classe de maior interesse.

As imagens apresentam resoluções variadas, típicas de câmeras urbanas e registros de trânsito, incluindo tanto imagens em alta resolução quanto outras com baixa nitidez ou compressão. Além disso, os cenários são diversos, abrangendo vias urbanas movimentadas, rodovias, diferentes condições climáticas e de iluminação, registros diurnos e noturnos, presença de sombras e veículos parcialmente ocultos. Os objetos aparecem em diferentes distâncias da câmera, com variações de tamanho e posição no frame, o que aumenta a complexidade da tarefa de detecção.

Na fase de preparação dos dados, serão realizadas etapas como a filtragem e seleção das classes de interesse (com foco na classe “ambulância”), a divisão dos dados em conjuntos de treino, validação e teste, além da inclusão de técnicas de aumento de dados (*data augmentation*), como rotação, ajuste de brilho e escala, para ampliar a variabilidade. Com essas etapas, espera-se obter um conjunto de dados consistente e representativo, capaz de suportar o treinamento de um modelo robusto para detecção de ambulâncias em cenários urbanos reais.

## **5. Resultados**

### **5.1. Aspectos éticos do uso da IA e responsabilidade no desenvolvimento da solução**

O desenvolvimento de sistemas baseados em Inteligência Artificial para monitoramento urbano, como o proposto neste projeto, envolve uma série de questões éticas que devem ser cuidadosamente consideradas, especialmente por lidar com dados visuais coletados em espaços públicos e por influenciar decisões automatizadas no trânsito.

Um dos principais aspectos éticos refere-se à privacidade e à proteção de dados. O uso das imagens provenientes das câmeras de monitoramento urbano para o treinamento e operação de modelos de IA deve respeitar legislações vigentes, como a Lei Geral de Proteção de Dados (LGPD), que estabelece diretrizes para o tratamento de dados pessoais e a proteção

da privacidade dos indivíduos (BRASIL, 2018). Dessa forma, é fundamental garantir que os dados utilizados sejam públicos, anonimizados ou devidamente autorizados, evitando a identificação de indivíduos e o uso indevido de informações sensíveis.

A confiabilidade do sistema e a robustez do modelo também são pontos críticos. Erros de detecção podem gerar impactos no trânsito, como abertura indevida de semáforos (falsos positivos) ou falha na priorização de ambulâncias (falsos negativos). Por isso, o modelo deve ser bem avaliado e utilizado, preferencialmente, como suporte à decisão, e não como sistema totalmente autônomo. A legislação brasileira também prevê o direito à revisão de decisões automatizadas, reforçando a importância da supervisão humana nesses sistemas (BRASIL, 2018).

Além disso, é importante garantir transparência nos critérios de funcionamento e atenção a possíveis vieses nos dados, que podem afetar o desempenho nos diferentes cenários urbanos.

Por fim, o projeto apresenta um impacto social positivo ao contribuir para a redução do tempo de resposta em emergências. No entanto, esse benefício depende de um desenvolvimento responsável, seguro e alinhado aos princípios éticos em todas as etapas da solução.

## 5.2. Detalhamento dos resultados completo

Inicialmente, foi realizado o treinamento de um modelo base utilizando a arquitetura YOLOv8n, sem aplicação de técnicas avançadas de pré-processamento ou inclusão de datasets adicionais e *data augmentation* personalizada (o modelo YOLOv8n já executa *data augmentation* por padrão). O processo foi configurado para 30 épocas de treinamento, com imagens de tamanho 640x640, utilizando o *dataset Emergency Vehicle Detection*.

A Tabela 1 apresenta as métricas de desempenho obtidas pelo modelo base e pela adaptação para a classe-alvo “Ambulância”. Observa-se que, nos modelos, os valores de *precision* e *recall* são elevados, indicando que o sistema consegue identificar corretamente a maioria dos objetos relevantes e apresenta baixo número de falsos positivos. O mAP@50 demonstrou alta eficiência sob critérios menos rigorosos, enquanto o mAP@50-95 e os fitness sugeriram espaço para aprimoramento em cenários mais desafiadores.

**Tabela 1. Métricas de desempenho do modelo**

| Métrica | Valor | Valor (Adaptação para classe alvo) | Descrição |
|---------|-------|------------------------------------|-----------|
|---------|-------|------------------------------------|-----------|

|                     |       |       |                                                                         |
|---------------------|-------|-------|-------------------------------------------------------------------------|
| Precision           | 0,967 | 0,973 | Proporção de detecções corretas em relação ao total de detecções feitas |
| Recall              | 0,973 | 0,983 | Capacidade do modelo de identificar todos os objetos relevantes         |
| mAP@50              | 0,983 | 0,992 | Média da precisão considerando IoU $\geq$ 0,50                          |
| mAP@50-95           | 0,747 | 0,711 | Média da precisão em múltiplos níveis de IoU (mais rigoroso)            |
| Fitness             | 0,747 | 0,711 | Métrica agregada baseada no desempenho geral do modelo                  |
| Tempo de inferência | ~2 ms | ~2 ms | Tempo médio para processar uma imagem                                   |
| Tempo total         | ~4 ms | ~4 ms | Inferência + pós-processamento                                          |

A Tabela 2 detalha o desempenho por classe. Nota-se que os valores de mAP@50-95 são relativamente equilibrados entre “Ambulance” (0,735), “Fire Engine” (0,739) e “Police Vehicle” (0,766). Essa homogeneidade sugere que o modelo não apresenta viés significativo para nenhuma classe específica, o que é positivo para a qualidade do dataset. Entretanto, o número de amostras por classe ainda é limitado (148, 121 e 177, respectivamente), o que pode impactar a capacidade de generalização em cenários urbanos mais variados e isso se reflete quando modelo considera apenas uma classe, ficando desbalanceado com 148 imagens para a classe ambulância e 298 para exemplos de não ambulância (tabela 3).

**Tabela 2. Desempenho por classe**

| Classe      | mAP@50-95 | Nº de amostras |
|-------------|-----------|----------------|
| Ambulance   | 0,735     | 148            |
| Fire Engine | 0,739     | 121            |



|                |       |     |
|----------------|-------|-----|
| Police Vehicle | 0,766 | 177 |
|----------------|-------|-----|

A Tabela 3 apresenta os resultados após a adaptação do modelo para a classe-alvo “Ambulância”. O valor de  $mAP@50-95$  obtido para essa etapa foi de 0,711, utilizando um total de 148 amostras. Comparando-se com o resultado do modelo base para a mesma classe (0,735), observa-se que adaptação gerou uma distorção da proporção do dataset, o modelo seguiu consistente, com uma leve piora. Mais exemplos de ambulâncias permitiram que o modelo extraísse uma maior performance dessa adaptação.

**Tabela 3. Desempenho por classe (Adaptação para classe alvo)**

| Classe    | $mAP@50-95$ | Nº de amostras |
|-----------|-------------|----------------|
| Ambulance | 0,711       | 148            |

De forma geral, os resultados obtidos demonstram que o modelo é capaz de atender aos objetivos iniciais do sistema, apresentando elevada precisão na detecção de veículos de emergência e desempenho adequado para aplicações em tempo real. Ademais, é possível visualizar como o modelo gerado lida e processa imagens e vídeos, rodando o *Notebook* com os códigos fonte e o uso de uma API válida para baixar o dataset, disponível no *GitHub* do projeto.

#### 5.4. Endereço GitHub e Endereço do vídeo no YouTube

O código-fonte e os experimentos realizados estão disponíveis no repositório GitHub, que reúne os *scripts* de treinamento, configuração do modelo e protótipo de detecção: [hyauss/DeteccaoEAlertaDeTransporteEmergencialViaImagens](https://github.com/hyauss/DeteccaoEAlertaDeTransporteEmergencialViaImagens)

Além disso, foi produzido um vídeo demonstrativo que evidencia o funcionamento do sistema em tempo real, reforçando a viabilidade prática da solução proposta:

<https://www.youtube.com/watch?v=WY3Cq58riY8>

## 6. Conclusão

O presente trabalho demonstrou a viabilidade da utilização de técnicas de Visão Computacional e Inteligência Artificial para a detecção automática de ambulâncias em cenários urbanos, utilizando a arquitetura YOLOv8n. Os resultados obtidos evidenciaram que o modelo apresentou elevados índices de *precision*, *recall* e  $mAP@50$ , além de baixo tempo de inferência, características fundamentais para aplicações em tempo real voltadas ao monitoramento inteligente do tráfego.

A comparação entre o modelo multiclasse e a adaptação para a classe-alvo “Ambulância” permitiu analisar os impactos da especialização do dataset. Embora tenha sido observada uma leve redução no valor de  $mAP@50-95$ , o modelo manteve comportamento consistente e desempenho satisfatório. Esse resultado evidencia que a limitação na quantidade de amostras da classe de interesse e o desbalanceamento do conjunto de dados influenciam diretamente a capacidade de generalização da rede neural.

Mesmo com essas limitações, o sistema demonstrou potencial para aplicações práticas em contextos de *Smart Cities*, podendo atuar como suporte à priorização de veículos de emergência por meio da integração com sistemas inteligentes de controle de tráfego. A possibilidade de utilizar câmeras urbanas já existentes torna a proposta mais acessível e escalável, reduzindo custos de infraestrutura quando comparada a soluções baseadas em sensores dedicados ou comunicação veicular.

Além disso, o desenvolvimento do protótipo permitiu validar não apenas o treinamento do modelo, mas também a capacidade de processar imagens e vídeos em tempo real, exibindo detecções e alertas de maneira funcional. Dessa forma, o projeto atingiu seus objetivos principais, demonstrando a aplicabilidade da solução no auxílio à mobilidade urbana e à redução do tempo de resposta em atendimentos emergenciais.

Como trabalhos futuros, recomenda-se a ampliação e balanceamento do dataset, especialmente com maior quantidade de imagens de ambulâncias em diferentes cenários urbanos, além da exploração de técnicas mais avançadas de *data augmentation* e testes com arquiteturas mais robustas. Também podem ser realizados experimentos integrando o sistema a semáforos inteligentes ou ambientes simulados de trânsito, permitindo avaliar o impacto da solução em situações próximas às condições reais de operação.

## 7. Referências

**BRASIL.** Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Diário Oficial da União, Brasília, 2018.

**EVERINGHAM, M.** et al. The Pascal Visual Object Classes (VOC) Challenge. *International Journal of Computer Vision*, 2010.

**KHAN, M. A.** et al. Smart traffic control system for emergency vehicles. *IEEE*, 2018.

**LECUN, Y.; BENGIO, Y.; HINTON, G.** Deep learning. *Nature*, v. 521, p. 436–444, 2015.

**PAN, S. J.; YANG, Q.** A Survey on Transfer Learning. *IEEE Transactions on Knowledge and Data Engineering*, v. 22, n. 10, p. 1345–1359, 2010.

**REDMON, J.** et al. You Only Look Once: Unified, Real-Time Object Detection. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.

**RUSSELL, S.; NORVIG, P.** *Artificial Intelligence: A Modern Approach*. 4. ed. Pearson, 2021.

**SINGH, A.; GUPTA, B.** Intelligent ambulance detection system. *Procedia Computer Science*, v. 167, p. 1881–1890, 2020.

**SZELISKI, R.** *Computer Vision: Algorithms and Applications*. Springer, 2010.

**ZHANG, S.** et al. Deep learning based vehicle detection. *IEEE Transactions on Intelligent Transportation Systems*, v. 18, n. 12, p. 3636–3647, 2017.